

Análise do Impacto de Variações de Prompting e Feedback Semântico no ARC-AGI-1

Fabio Luiz da C. Cieslak Matheus Machado

Universidade Federal do Rio Grande do Sul

Setembro 2026

- O benchmark ARC-AGI-1 avalia raciocínio indutivo e generalização.
- Modelos costumam recorrer a sobreajustes espúrios (ramificações *if/else*).
- **Nossa abordagem:** Utilizar a síntese indutiva guiada por contraexemplos (CEGIS) com regras Anti-Trapaça.

- **Avaliação:** 100 tarefas do conjunto de treino do ARC-AGI-1.
- **Modelos avaliados:** 9 modelos de linguagem (fronteira, intermediários e compactos).
- **Métricas Analisadas:**
 - Acurácia (sucesso estrito no teste cego).
 - Custo iterativo (requisições por tarefa).
 - Taxonomia de erros (Recuperação vs. Regressão).
- **Inferência Estatística:** Reamostragem Bootstrap (10.000 iterações).

Resultados: Desempenho e Eficiência

Modelo	CEGIS	Anti-Trapaça	Δ	Req./Tarefa	Recuperação
Grok 4.6	92	92	+0	1.13	4
DeepSeek V4 Flash 0731	86	86	+0	1.25	12
GPT-5.6 Luna	77	79	+2	2.00	19
Claude Sonnet 5	62	60	-2	2.90	30
Gemini 3.5 Flash Lite	43	45	+2	3.23	22
Gemini 3.1 Flash Lite	31	24	-7	4.07	19
GLM 5.3 Flash	19	17	-2	4.42	9
Leanstral 1.5.1	7	9	+2	4.69	4
GPT-5.4 Nano	5	3	-2	4.89	4

Destaque: A regra Anti-Trapaça alavancou os modelos intermediários. Foram observadas **zero regressões** em todos os testes.

Resultados: Validação Estatística e Erros

Modelo	p_{boot}	IC 95% Bootstrap	Sobreajuste Espúrio	Teto Repres.
Grok 4.6	0.0431	[1.0%, 8.0%]	8	0
DeepSeek V4 Flash 0731	0.0007	[6.0%, 19.0%]	10	4
GPT-5.6 Luna	0.0001	[12.0%, 27.0%]	10	13
Claude Sonnet 5	0.0001	[21.0%, 39.0%]	7	31
Gemini 3.5 Flash Lite	0.0001	[14.0%, 30.0%]	10	47
Gemini 3.1 Flash Lite	0.0001	[12.0%, 27.0%]	7	62
GLM 5.3 Flash	0.0052	[4.0%, 15.0%]	0	81
Leanstral 1.5.1	0.0457	[1.0%, 8.0%]	0	93
GPT-5.4 Nano	0.0496	[1.0%, 8.0%]	0	95

Análise: Ganhos estatisticamente significantes ($p < 0.05$) em toda a escala de modelos. Modelos compactos esbarram no **Teto de Representação**.

- **Eficácia do CEGIS:** A retroalimentação semântica baseada em contraexemplos gera ganhos consistentes (com avanços de até +30%).
- **Segurança Estrutural:** Preservação total de acertos prévios ao longo dos ciclos iterativos (estrita monotonicidade).
- **Impacto do Anti-Trapaça:** Mitigou o sobreajuste espúrio, trazendo benefícios visíveis para modelos intermediários.
- **Rigor Metodológico:** O Bootstrap permitiu discernir aprimoramentos reais do ruído estocástico, criando um modelo de validação escalável.

Obrigado

Código e Dados: github.com/Jubarte27/arc-agi-1