

ARC-AGI-1

Experimento comparativo Baseline x CEGIS

Grupo C - Fábio Cieslak, Izadora Candotti e Matheus Machado

CEGIS - Counterexample-Guided Inductive Synthesis


Ciclo iterativo de geração e validação que permite que a LLM refine a resposta, baseando-se em feedbacks que recebe sobre o desempenho das tentativas anteriores.

O contra exemplo fornece as seguintes informações:

- A **entrada** do exemplo de treino específico onde o código falhou.
- O **gabarito** oficial correspondente a entrada.
- O **resultado** real gerado pela execução do código da LLM dentro do sandbox (verificador).

Critério de Parada: O ciclo termina ao acertar 100% dos treinos ou ao esgotar o teto de 5 tentativas.

Fluxo do Experimento



Como a LLM Recebe as Informações

Fase Inicial

Prompt Inicial

Apresenta a **task** e os **casos de exemplo** e

solicita que a LLM retorne:

- Uma estratégia em **linguagem natural**
- Um bloco de **código python** que implemente a solução encontrada.

Ciclo de Feedback

Também recebe o histórico das respostas anteriores

Prompt com Contraexemplo

“

Your code failed on Training Example

[example_idx]

Input: [input_grid]

Expected Output: [expected_grid]

Produced Output: [output_string]

[CODE_RULES]

Analyze the discrepancy, fix your logic, and provide the updated 'transform(grid)' function inside a "python ..." block.

”

Resposta da LLM

Linguagem Natural (string de texto contendo a estratégia) + **Código python** (no padrão:

```
transform(grid: list[list[int]]) -> list[list[int]]  
)
```

Exemplo de estrutura da resposta:

The strategy to solve the task...

```
“python  
def transform(grid):  
    return [[cell * 2 for cell in row]  
    for row in grid]  
“
```

Critério de Avaliação da Resposta



CORRETA


se a função `transform(grid)` retornada pela LLM passar em todos os casos de testes ocultos.



INCORRETA


se a função `transform(grid)` retornada pela LLM falhar em algum dos testes ocultos.

Efeitos Qualitativos avaliados




Comparação de Desempenho


Exp 1 100 tasks resolvidas com Gemini Flash-Lite



Exp 2 100 tasks resolvidas com Gemini Flash-Lite após alteração do prompt.



Eficiência e Custo de Execução



Comparação entre

precisão (**mais acertos**) e
custo (**número de
chamadas**).


?

Onde está o gargalo ?
No método de síntese (CEGIS) ou na
capacidade do modelo Gemini
Flash-Lite?

Analisando as causas das tarefas não resolvidas.

Comparação de Desempenho

Nemotron-3 Ultra 550B (137 Tarefas)



DeepSeek-V4 Flash (96 Tarefas)

