

Síntese de Programas com CEGIS e Restrições Anti-Overfitting no ARC-AGI

Uma Análise Estrutural e Estatística

Fabio Luiz da Costa Cieslak Izadora Candotti de Oliveira Matheus Machado

Universidade Federal do Rio Grande do Sul (UFRGS)

2026

Contexto: ARC-AGI e Síntese de Programas

- ▶ Desafio de **raciocínio indutivo** com 2–5 demonstrações visuais inéditas
- ▶ Avaliação **cega e estrita** por acerto binário na **grade de teste oculta**
- ▶ Síntese de função determinística **transform(grid)** em Python nativo
- ▶ Execução via interpretador elimina **falhas de contagem** e ruído textual

Abordagens Avaliadas: Baseline vs. CEGIS

- ▶ Geração estática em **tentativa única (1-Shot)**, sem mecanismos de reparo
- ▶ Refinamento **iterativo guiado por contraexemplos (CEGIS)** em até 5 rodadas
- ▶ Execução isolada em **sandbox determinístico** nos pares de treino
- ▶ Retorno do **primeiro contraexemplo** à LLM para correção de código

Estratégia Proposta (AntiCheat) e Hipótese

- ▶ Vedação explícita a **atalhos** e **coordenadas fixas** das grades de treino
- ▶ Obrigatoriedade de enunciar o **invariante abstrato** antes de emitir o código


Hipótese Central de Pesquisa

“Restrições semânticas anti-hardcoding e reflexão sobre invariantes melhoram a acurácia no teste oculto do ARC-AGI?”

Escala Experimental e Protocolo Pareado

- ▶ Amostra de **100 tarefas** avaliadas em **8 modelos** (**800 testes pareados**)
- ▶ Ampla cobertura em três faixas de capacidade de LLMs:
 - **Fronteira** com Grok 4.6, DeepSeek V4 Flash e GPT-5.6 Luna
 - **Intermediários** com Claude Sonnet 5 e família Gemini Flash
 - **Compactos** com Leantral 1.5.1 e GPT-5.4 Nano
- ▶ Execução determinística **rigorosamente pareada** entre CEGIS e AntiCheat
- ▶ Critério de avaliação por **acerto binário estrito** na grade de teste oculta

Distribuição de Resolução das Tarefas




Eficácia do CEGIS sobre o Baseline (1-Shot)

Modelo	Baseline (1-Shot)	CEGIS (Iterativo)	Ganho Absoluto (Δ)
Grok 4.6	88%	92%	+4%
DeepSeek V4 Flash 0731	74%	86%	+12%
GPT-5.6 Luna	58%	77%	+19%
Claude Sonnet 5	32%	62%	+30%
Gemini 3.5 Flash Lite	21%	43%	+22%
Gemini 3.1 Flash Lite	12%	31%	+19%
Leanstral 1.5.1	3%	7%	+4%
GPT-5.4 Nano	1%	5%	+4%
Total Agregado (800 testes)	36,1%	50,4%	+14,3%

Resultados Globais: CEGIS vs. AntiCheat

Modelo	CEGIS (%)	AntiCheat (%)	Vitórias (b/c)	p-valor bruto	p ajustado (Bonf.)
Grok 4.6	92,0%	92,0%	0 / 0	1,0000	1,0000
DeepSeek V4 Flash 0731	86,0%	86,0%	0 / 0	1,0000	1,0000
GPT-5.6 Luna	77,0%	79,0%	2 / 4	0,6875	1,0000
Claude Sonnet 5	62,0%	60,0%	5 / 3	0,7266	1,0000
Gemini 3.5 Flash Lite	43,0%	45,0%	6 / 8	0,7905	1,0000
Gemini 3.1 Flash Lite	31,0%	24,0%	7 / 0	0,0156	0,1250
Leanstral 1.5.1	7,0%	9,0%	2 / 4	0,6875	1,0000
GPT-5.4 Nano	5,0%	3,0%	3 / 1	0,6250	1,0000
Total Agregado	50,4%	49,8%	25 / 20	0,5515	—

Matriz de Discrepância das Estratégias



Testes de Significância Estatística

Teste Estatístico	Configuração	Valor / Intervalo	Conclusão
Teste Binomial Exato	Casos Discordantes ($b = 25, c = 20$)	$p = 0,5515$	Não significativa
Teste de Permutação	100.000 iterações pareadas	$p = 0,5501$	Não significativa
Intervalo de Confiança Bootstrap	10.000 reamostragens (95%)	$[-2,25\%, +1,00\%]$	Contém o zero
Correção de Bonferroni	Gemini 3.1 ($k = 8$ modelos)	$p_{\text{adj}} = 0,1250$	Não significativa

Diagnóstico de Falhas e Varredura de Código

Dimensão Avaliada	Ocorrências	Percentual	Diagnóstico
Teto de Representação (CEGIS venceu)	23 em 25	92,0%	Falha no treino
Teto de Representação (AntiCheat venceu)	18 em 20	90,0%	Falha no treino
Sobreajuste Espúrio nos Casos Discordantes	4 em 45	8,9%	Raro
Trapaças por Coordenadas Fixas	7 em 2.398	0,29%	Residual


Diagnóstico Qualitativo: Viés e Gargalo Real

- ▶ LLMs apresentam **viés algorítmico natural**, com trapaças residuais de apenas 0,29%
- ▶ Códigos gerados sob CEGIS e AntiCheat são **estruturalmente quase idênticos**
- ▶ Mais de 90% **das falhas** decorrem da incapacidade de resolver os treinos (**teto de representação**)
- ▶ Instruções no prompt **não expandem** o espaço de hipóteses indutivo do modelo

Métricas Psicométricas de Guttman

Métrica Psicométrica	Valor Obtido	Limiar de Aceitação	Status
Coeficiente de Reprodutibilidade (<i>CR</i>)	0,9738	$\geq 0,90$	Confirmado
Reprodutibilidade Marginal Mínima (<i>MMR</i>)	0,7887	—	Linha de Base
Coeficiente de Escalabilidade (<i>CS</i>)	0,8757	$\geq 0,60$	Escala Forte
Subsunção Grok 4.6 → DeepSeek V4	100,0%	—	Monotônica
Subsunção DeepSeek V4 → GPT-5.6	97,4%	—	Quase Perfeita


Distribuição de Complexidade de Código



Complexidade Estrutural e a Navalha de Occam

Desfecho da Execução	Amostras	SLOC Médio	Laços	Condicionais	Profundidade AST
Acerto de Primeira	289	34,6	6,2	4,9	12,2
Recuperado via CEGIS	114	44,5	7,6	7,0	12,7
Sobreajuste Espúrio	52	55,9	8,8	8,7	13,1
Falha no Treino	342	44,4	7,9	7,5	12,8
Inchaço no Sobreajuste	—	1,61×	—	—	$p = 5,15 \times 10^{-9}$

Dinâmica de Recuperação por Iteração



Dinâmica de Iterações do CEGIS

Iteração	Tarefas Resolvidas	% do Total Resolvido	Tarefas Recuperadas	% Acumulado
1	289	71,7%	0	0,0%
2	69	17,1%	69	60,5%
3	29	7,2%	29	86,0%
4	9	2,2%	9	93,9%
5	7	1,7%	7	100,0%

Diretrizes Práticas para Síntese de Programas

- ▶ Aplicação de **penalidade de complexidade por AST** baseada em nós e SLOC
- ▶ **Poda automática de ramificações** com inchaço estrutural para evitar sobreajuste
- ▶ Adoção de **parada precoce em 3 iterações**, retendo 86% **dos reparos viáveis**
- ▶ Economia de mais de 45% **em chamadas de API** e tempo de inferência

Conclusões

- ▶ Refinamento por **CEGIS supera o Baseline em +14,3%** (114 tarefas recuperadas)
- ▶ Restrições **AntiCheat são estatisticamente equivalentes** ao CEGIS padrão ($p = 0,5515$)
- ▶ Principal gargalo reside no **teto de representação** ($> 90\%$), e não em trapaças (0,29%)
- ▶ ARC-AGI exhibe **escala de Guttman unidimensional** ($CR = 0,9738$) e **inchaço de Occam** ($1,61\times$)

Encerramento

Obrigado!

Perguntas e Discussão

Grupo C – UFRGS

Fábio Cieslak • Izadora Candotti • Matheus Machado