

Experimento Comparativo Baseline x CEGIS

ARC-AGI-1

Grupo C – Fábio Cieslak, Izadora Candotti e Matheus Machado

2026

CEGIS - Counterexample-Guided Inductive Synthesis


Ciclo iterativo de geração e validação que permite que a LLM refine a resposta, baseando-se em feedbacks que recebe sobre o desempenho das tentativas anteriores.

O contra-exemplo fornece as seguintes informações:

- A **entrada** do exemplo de treino específico onde o código falhou.
- O **gabarito** oficial correspondente à entrada.
- O **resultado** real gerado pela execução do código da LLM dentro do sandbox (verificador).

Critério de Parada: O ciclo termina ao acertar 100% dos treinos ou ao esgotar o teto de 5 tentativas.

Custom Graph Layout



Como a LLM Recebe as Informações

Fase Inicial (Prompt Inicial)

- Apresenta a *task* e os casos de exemplo.
- Solicita que a LLM retorne:
 - Uma estratégia em linguagem natural.
 - Um bloco de código Python que implemente a solução encontrada.

Ciclo de Feedback (Prompt com Contraexemplo)

- Recebe o histórico das respostas anteriores.
- Mensagem de erro estruturada:

Your code failed on Training Example [idx]

Input: [input_grid]

Expected Output: [expected_grid]

Produced Output: [output_string]

[CODE_RULES]

Analyze discrepancy, fix logic, and provide updated `transform(grid)` function.

Resposta da LLM

Formato Esperado:

- **Linguagem Natural:** String de texto contendo a estratégia detalhada.
- **Código Python:** No padrão obrigatório:

```
def transform(grid: list[list[int]]) -> list[list[int]]:
```

Exemplo de Estrutura da Resposta:

The strategy to solve the task is to double each element [...]

```
```python
```

```
def transform(grid):
```

```
 return [[cell * 2 for cell in row] for row in grid]
```

```
```
```

Critério de Avaliação da Resposta

CORRETA

Se a função `transform(grid)` retornada pela LLM passar em **todos** os casos de testes ocultos.

INCORRETA

Se a função `transform(grid)` retornada pela LLM falhar em **algum** dos testes ocultos.

Efeitos Qualitativos Avaliados

Execução do Verificador

Passou no treino

Validação com testes ocultos

Falhou no treino

Investigação de falhas e recuperação

Principais Causas de Falha:

- **Recuperação Semântica:** Dificuldade em corrigir o raciocínio fundamental.
- **Falsa Convergência:** Falha por sobreajuste artificial (*overfitting*).
- **Esgotamento:** Esgota as tentativas sem solucionar o treino.

Comparação de Desempenho (Gemini Flash-Lite)

Exp 1: CEGIS Padrão (100 tasks, Gemini Flash-Lite)

- Resolvido no Baseline: **39.0%**
- Ganho do CEGIS: **8.0%**
- Não Resolvido: **53.0%**

Exp 2: Com Ajuste de Prompt (100 tasks, Gemini Flash-Lite)

- Resolvido no Baseline: **39.0%**
- Ganho do CEGIS: **16.0%**
- Não Resolvido: **45.0%**

A melhoria no prompt aumentou significativamente a eficácia do ganho por CEGIS.

Eficiência e Custo de Execução

| Métrica | Baseline (1-Shot) | Exp 1: CEGIS Padrão | Exp 2: CEGIS (+ Anti-Cheat) |
|----------------------|-------------------|---------------------|-----------------------------|
| Total de Requisições | 100 | 341 | 300 |
| Acurácia (%) | 39% | 55% | 60% |

Comparação direta entre precisão (mais acertos) e custo (número de chamadas de API).

O experimento 2 otimizou o número de requisições mantendo alta acurácia.

Onde está o gargalo?

Onde está o gargalo?

No método de síntese (CEGIS) ou na capacidade do modelo Gemini Flash-Lite?

Analisando as causas das tarefas não resolvidas e testando com outros modelos de linguagem.

Comparação com Outros Modelos

Nemotron-3 Ultra 550B (137 Tarefas)

- Resolvido no Baseline: **25.5%**
- Ganho do CEGIS: **19.7%**
- Não Resolvido: **54.7%**

DeepSeek-V4 Flash (96 Tarefas)

- Resolvido no Baseline: **32.3%**
- Ganho do CEGIS: **25.0%**
- Não Resolvido: **42.7%**