

Síntese de Programas com CEGIS e Restrições Anti-Overfitting no ARC-AGI

Fabio Luiz da Costa Cieslakk, Izadora Candotti de Oliveira e Matheus Machado

Universidade Federal do Rio Grande do Sul

ARC-AGI

Desafio de **raciocínio indutivo** baseado em transformações de grids coloridos a partir de demonstrações visuais

Síntese de Programas

- ▶ Síntese de função em Python que busca resolver a tarefa de transformação:
`def transform(grid: list[list[int]]) -> list[list[int]]:`
- ▶ Criado a partir da grade de **treinamento**
- ▶ Avaliação por acerto binário na grade de teste **oculta**

Abordagens Avaliadas

Baseline:

- ▶ Geração estática em **tentativa única (1-Shot)**, sem mecanismos de reparo

CEGIS:

- ▶ Refinamento **iterativo guiado por contraexemplos (CEGIS)** em até 5 rodadas
- ▶ Retorno do **primeiro contraexemplo** à LLM para correção de código

Estratégia Proposta (AntiCheat)

- ▶ Proibição de uso de **atalhos** ou **coordenadas fixas** nas grades de treino
- ▶ Obrigatoriedade de enunciar o **invariante abstrato** antes de emitir o código

Hipótese Central

“Restrições semânticas anti-hardcoding e reflexão sobre invariantes melhoram a acurácia no teste oculto do ARC-AGI”

Escala Experimental

- ▶ Amostra de **100 tarefas** avaliadas em **8 modelos** (**800 testes pareados**)
- ▶ Cobertura em três faixas de capacidade de LLMs:
 - **Fronteira** com Grok 4.6, DeepSeek V4 Flash e GPT-5.6 Luna
 - **Intermediários** com Claude Sonnet 5 e família Gemini Flash
 - **Compactos** com Leantral 1.5.1 e GPT-5.4 Nano


Eficácia do CEGIS sobre o Baseline (1-Shot)

Modelo	Baseline (1-Shot)	CEGIS (Iterativo)	Ganho Absoluto (Δ)
Grok 4.6	88%	92%	+4%
DeepSeek V4 Flash 0731	74%	86%	+12%
GPT-5.6 Luna	58%	77%	+19%
Claude Sonnet 5	32%	62%	+30%
Gemini 3.5 Flash Lite	21%	43%	+22%
Gemini 3.1 Flash Lite	12%	31%	+19%
Leanstral 1.5.1	3%	7%	+4%
GPT-5.4 Nano	1%	5%	+4%
Total Agregado (800 testes)	36,1%	50,4%	+14,3%


Resultados Globais: CEGIS vs. AntiCheat

Modelo	CEGIS (%)	AntiCheat (%)	Vitórias (b/c)	p-valor bruto	p ajustado (Bonf.)
Grok 4.6	92,0%	92,0%	0 / 0	1,0000	1,0000
DeepSeek V4 Flash 0731	86,0%	86,0%	0 / 0	1,0000	1,0000
GPT-5.6 Luna	77,0%	79,0%	2 / 4	0,6875	1,0000
Claude Sonnet 5	62,0%	60,0%	5 / 3	0,7266	1,0000
Gemini 3.5 Flash Lite	43,0%	45,0%	6 / 8	0,7905	1,0000
Gemini 3.1 Flash Lite	31,0%	24,0%	7 / 0	0,0156	0,1250
Leanstral 1.5.1	7,0%	9,0%	2 / 4	0,6875	1,0000
GPT-5.4 Nano	5,0%	3,0%	3 / 1	0,6250	1,0000
Total Agregado	50,4%	49,8%	25 / 20	0,5515	—

Distribuição de Resolução das Tarefas



Matriz de Discrepância das Estratégias



Testes de Significância Estatística

Teste Estatístico	Valor / Intervalo	Conclusão
Teste Binomial Exato	$p = 0,5515$	Não significativa
Teste de Permutação	$p = 0,5501$	Não significativa
Intervalo de Confiança Bootstrap	$[-2,25\%, +1,00\%]$	Contém o zero
Correção de Bonferroni ao Gemini 3.1	$p_{\text{adj}} = 0,1250$	Não significativa


Diagnóstico Qualitativo: Viés e Gargalo Real

- ▶ Códigos gerados sob CEGIS e AntiCheat são **estruturalmente quase idênticos**
- ▶ Mais de 90% **das falhas** decorrem da incapacidade de resolver os treinos (**teto de representação**)

Hierarquia de Tarefas

- ▶ Tarefas seguem um modelo quase que totalmente **hierárquico**
- ▶ Grok 4.6 (1º) acertou **100%** das tarefas que o DeepSeek V4 (2º) acertou
- ▶ DeepSeek V4 (2º) acertou **97,4%** das tarefas que o GPT-5.6 Luna (3º) acertou

Dinâmica de Recuperação por Iteração



Dinâmica de Iterações do CEGIS

Iteração	Tarefas Resolvidas	% do Total Resolvido	Tarefas Recuperadas	% Acumulado
1	289	71,7%	0	0,0%
2	69	17,1%	69	60,5%
3	29	7,2%	29	86,0%
4	9	2,2%	9	93,9%
5	7	1,7%	7	100,0%

Conclusões

- ▶ Refinamento por **CEGIS supera o Baseline em +14,3%** (114 tarefas recuperadas)
- ▶ Restrições **AntiCheat são estatisticamente equivalentes** ao CEGIS padrão ($p = 0,5515$)
- ▶ Principal gargalo reside no **teto de representação ($> 90\%$)**, e não em trapaças (0,29%)

Encerramento

Obrigado!

Perguntas e Discussão

Grupo C – UFRGS

Fábio Cieslak • Izadora Candotti • Matheus Machado